ACTIVIDAD 5. EVALUACIÓN

Daniela Pérez Lugo | A01735108

Regresión lineal simple, regresión lineal múltiple y regresión logística

El análisis de datos permite transformar los registros de ventas e inventario en información útil para la toma de decisiones. Mediante técnicas estadísticas y de aprendizaje automático es posible identificar asociaciones entre las características de las transacciones y sus importes, así como construir modelos que clasifiquen operaciones de acuerdo con su valor económico.

En esta evaluación se aplican tres técnicas de modelado: **regresión lineal simple, regresión lineal múltiple y regresión logística.** Las dos primeras permiten analizar y estimar una variable cuantitativa, mientras que la tercera se utiliza para resolver una tarea de clasificación binaria.

El trabajo utiliza información **histórica de ventas** y contempla variables numéricas y categóricas. Además, incorpora una revisión de la calidad de los datos, la identificación de posibles valores atípicos y una división entre conjuntos de entrenamiento y prueba para evaluar el desempeño de los modelos.

2. Objetivos

2.1 Objetivo general

Analizar los datos de ventas e inventario para identificar variables asociadas con el importe neto de las transacciones y desarrollar modelos de regresión y clasificación que contribuyan a la comprensión del comportamiento comercial.

2.2 Objetivos específicos

- Examinar la estructura, los valores faltantes, los registros duplicados y los posibles valores atípicos de las bases de datos.
- Desarrollar un modelo de regresión lineal simple para estudiar la relación entre una variable cuantitativa y el importe neto.
- Construir un modelo de regresión lineal múltiple que incorpore variables numéricas y categóricas.

- Entrenar un modelo de regresión logística que clasifique las ventas como de importe alto o no alto.
- Comparar los resultados mediante métricas estadísticas apropiadas.
- Interpretar los hallazgos desde una perspectiva comercial, reconociendo las limitaciones de los datos y de los modelos.

3. Descripción de los datos

El archivo de origen es *Datos_Complementarios_CLV.xlsx* y contiene tres hojas principales.

Hoja	Registros	Columnas
Existencias_15_10_2026	2,951	6
Histórico_Entradas_Salidas	55,180	7
Histórico_Ventas	21,632	14

La hoja Histórico_Ventas constituye la fuente principal para los modelos predictivos. Entre sus variables destacan:

- **total_neto:** importe neto de la transacción; es la variable objetivo de las regresiones lineales.
- **precio_unitario:** precio registrado por unidad.
- **total_unidades:** cantidad de unidades vendidas.
- **marc:** marca del producto.
- **estado:** entidad federativa asociada al registro comercial.
- **fecha_documento:** fecha de la operación, de la cual se derivaron el mes y el día de la semana.

Para la regresión múltiple y la logística se utilizaron el precio unitario, el total de unidades, el mes, la marca y el estado. Se excluyeron los identificadores, folios y nombres de clientes como predictores.

4. Metodología

El análisis se realizó con Python y las bibliotecas Pandas, NumPy, Matplotlib y Scikit-learn.

El procedimiento incluyó la carga de las tres hojas de cálculo, la normalización de los nombres de las columnas, la revisión de calidad, la conversión de fechas, el análisis de valores atípicos y el entrenamiento de los modelos.

Para evaluar los modelos se utilizó una división aleatoria con random_state=42 y un 80 % de los registros para entrenamiento y un 20 % para prueba. Los resultados reportados corresponden a la partición de prueba obtenida durante la ejecución del notebook.

4.1 Criterios de preparación

Los valores faltantes de la columna "cp" se conservaron en la base original. En los modelos, los datos faltantes de las variables predictoras se trataron mediante imputación dentro de los procesos de preprocesamiento.

Los posibles valores atípicos se identificaron con el método del rango intercuartílico (IQR). No se eliminaron automáticamente, ya que los importes y cantidades elevados podrían corresponder a operaciones comerciales legítimas.

4.2 Definición de venta de importe alto

Para la regresión logística se definió la variable binaria venta_alta utilizando el percentil 75 del importe neto del conjunto de entrenamiento.

Una venta se clasificó como alta cuando su importe neto superó el umbral de **$2,155.18**. Este criterio permite identificar aproximadamente el cuartil superior de las transacciones según la distribución del entrenamiento.

El umbral se calculó antes de evaluar el conjunto de prueba y el sobremuestreo de la clase minoritaria se aplicó exclusivamente al entrenamiento.

5. Análisis exploratorio y calidad de los datos

5.1 Valores faltantes y duplicados

La hoja Histórico_Ventas contiene 492 valores faltantes en la columna cp, equivalentes al 2.27 % de sus registros. No se encontraron valores faltantes en las hojas de existencias ni de movimientos.

También se identificaron 185 filas completamente duplicadas en el histórico de ventas. Esto representa aproximadamente el 0.86 % de los registros.

Los duplicados deben revisarse antes de eliminarlos. Una repetición exacta puede deberse a un error de extracción, pero también es necesario verificar que no existan operaciones legítimas con datos idénticos.

5.2 Distribución de variables numéricas

El importe neto promedio registrado fue de $5,388.64, mientras que la mediana fue de $948.28. La diferencia entre ambas medidas sugiere una distribución asimétrica, influida posiblemente por transacciones de importe elevado.

El precio unitario presentó un promedio de $4,337.61 y una mediana de $614.69. El máximo registrado fue de $2,170,948.28.

Se identificaron 1,612 registros con precio unitario igual a cero y también 1,612 con total_neto igual a cero. No se detectaron valores negativos en estas variables ni en total_unidades.

Estos registros deben investigarse para determinar si corresponden a muestras, promociones, movimientos especiales, errores de captura u otras operaciones que requieran un tratamiento específico.

5.3 Valores atípicos

El método IQR identificó los siguientes posibles valores atípicos:

Variable	Casos identificados	Porcentaje
precio_unitario	1,076	4.97 %
total_unidades	3,659	16.91 %
total_neto	2,150	9.94 %

Los resultados muestran que las cantidades vendidas presentan una proporción relativamente alta de observaciones fuera del rango intercuartílico habitual.

La identificación de un valor atípico no implica que el dato sea incorrecto. Antes de excluirlo, se recomienda verificar su correspondencia con facturas, cantidades vendidas y políticas comerciales.

Hallazgo de calidad: es conveniente revisar los duplicados, los importes en cero y las transacciones de importe elevado antes de utilizar los modelos para decisiones operativas.

6. Regresión lineal simple

6.1 Objetivo

Estudiar la relación entre una variable cuantitativa y el importe neto de las ventas, utilizando como variable predictora la que presentó la mayor correlación absoluta con total_neto.

6.2 Variable seleccionada

La variable seleccionada automáticamente fue precio_unitario, con una correlación de Pearson de **0.9927**.

Esta correlación positiva indica una asociación lineal muy fuerte: en los datos observados, los precios unitarios más elevados tienden a estar asociados con importes netos mayores.

6.3 Ecuación estimada

La ecuación obtenida fue:

total_neto = 1,062.0294 + (1.0008 × precio_unitario)

El coeficiente del precio unitario es positivo. En términos del modelo, un incremento de una unidad monetaria en el precio unitario se asocia con un incremento estimado de aproximadamente 1.0008 unidades monetarias en el importe neto, manteniendo la forma lineal del modelo.

Esta interpretación describe la ecuación ajustada y no debe considerarse una relación causal.

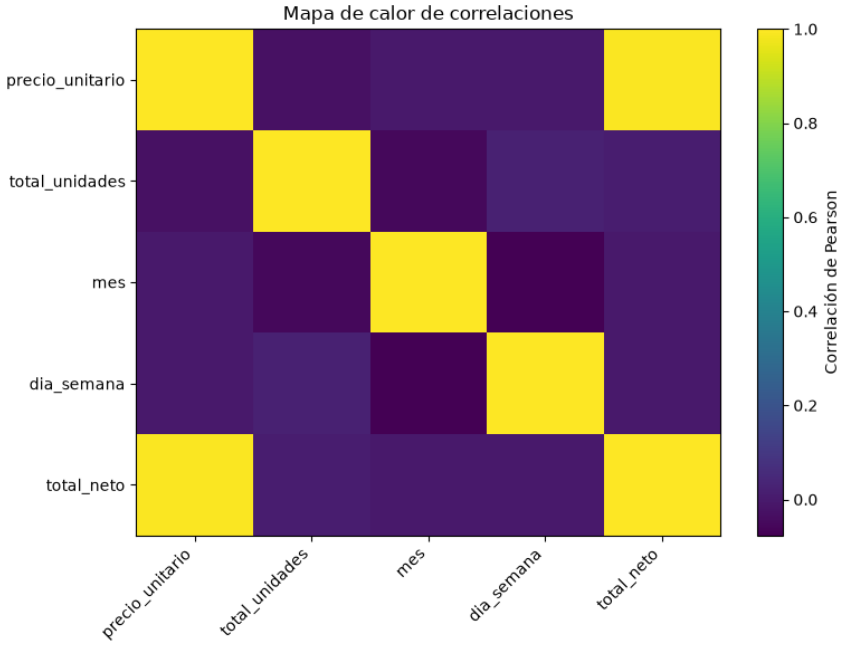
6.4 Resultados

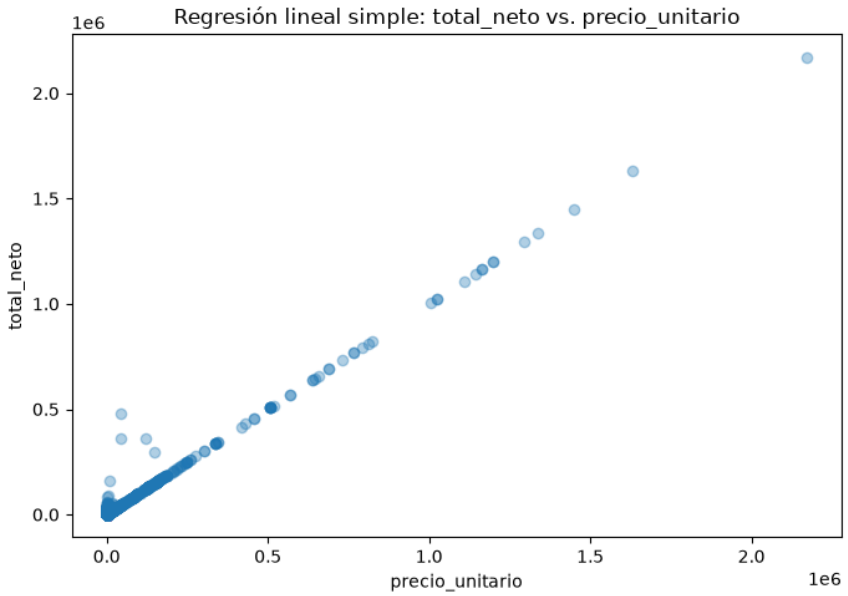
Métrica	Resultado
R^2 de entrenamiento	0.9845
R^2 de prueba	0.9915
MAE de prueba	1,463.42

Métrica	Resultado
RMSE de prueba	3,189.58

El R^2 de prueba indica que el modelo explica aproximadamente el 99.15 % de la variabilidad observada de total_neto en la partición evaluada.

El MAE representa el error absoluto medio de las predicciones, mientras que el RMSE penaliza con mayor intensidad los errores de mayor magnitud. El RMSE superior al MAE sugiere que algunas observaciones presentan errores relativamente grandes.



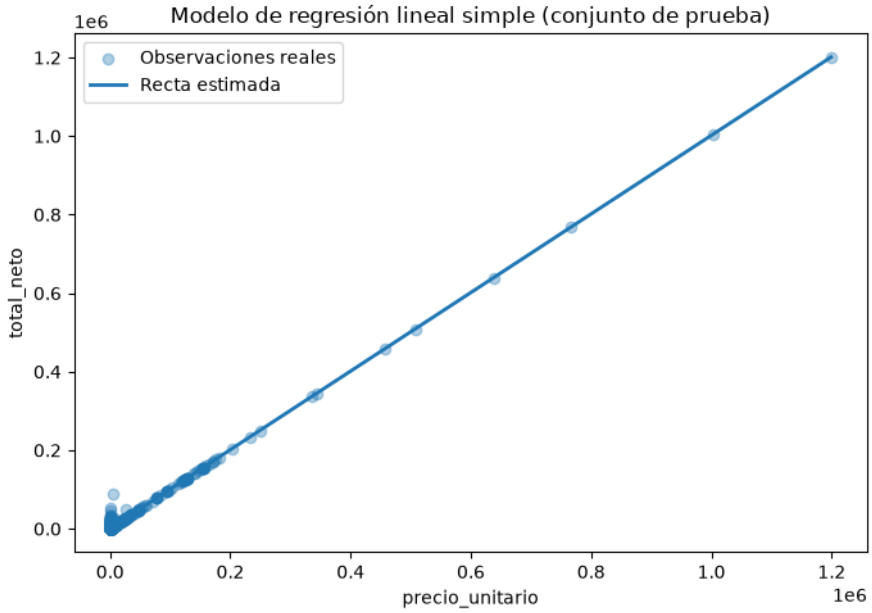


6.5 Interpretación

El modelo presenta un ajuste elevado y confirma la fuerte asociación entre precio_unitario y total_neto.

No obstante, el resultado debe interpretarse con precaución, debido a que el importe neto puede depender directamente del precio y de las unidades facturadas. Asimismo, los importes extremos pueden influir considerablemente en las métricas.

Por lo tanto, el modelo constituye una referencia útil para el análisis exploratorio, pero su capacidad predictiva independiente debe comprobarse con una validación adicional.



7. Regresión lineal múltiple

7.1 Objetivo

Construir un modelo que estime total_neto a partir de varias características de las transacciones, con el propósito de evaluar si la incorporación de información adicional mejora el ajuste.

7.2 Variables utilizadas

Se incluyeron las siguientes variables:

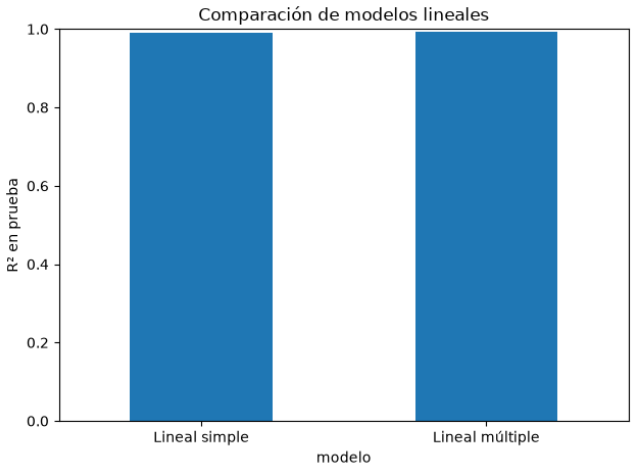
- Precio unitario.
- Total de unidades.
- Mes de la operación.
- Marca del producto.
- Estado asociado a la venta.

Las variables categóricas se transformaron mediante codificación One-Hot Encoding. Para los valores faltantes de las variables numéricas se utilizó la mediana, mientras que para las categóricas se utilizó la categoría más frecuente.

El preprocesamiento se ajustó utilizando únicamente los datos de entrenamiento.

7.3 Resultados

Métrica	Resultado
R^2 de entrenamiento	0.9864
R^2 de prueba	0.9938
MAE de prueba	1,189.35
RMSE de prueba	2,729.65



El R^2 de prueba fue de 0.9938, equivalente a aproximadamente el 99.38 % de la variabilidad explicada dentro de la partición evaluada.

Los errores MAE y RMSE fueron menores que los obtenidos por la regresión simple.

7.4 Comparación con el modelo simple

El modelo múltiple incrementó el R^2 de prueba de 0.9915 a 0.9938. Además, el MAE disminuyó de $1,463.42 a $1,189.35 y el RMSE pasó de $3,189.58 a $2,729.65.

Esto representa una reducción aproximada del 18.7 % en el MAE y del 14.4 % en el RMSE.

Los resultados indican una mejora del ajuste en el conjunto de prueba. Sin embargo, el incremento del R^2 es relativamente pequeño, porque el modelo simple ya presentaba un ajuste muy elevado.

7.5 Interpretación de los coeficientes

Entre los coeficientes de mayor magnitud absoluta aparecieron las categorías de marca VITA, AG y AIDITE, así como determinadas categorías de estado y la variable total_unidades.

Estos coeficientes representan diferencias estimadas respecto de las categorías de referencia y bajo las demás condiciones incluidas en el modelo. No deben interpretarse como efectos causales ni como evidencia suficiente para afirmar que una marca o estado provoca mayores ventas.

La magnitud de los coeficientes categóricos también depende de la escala del modelo y de la composición de las observaciones.

7.6 Evaluación

La regresión múltiple fue el mejor modelo de regresión lineal entre los dos evaluados, considerando conjuntamente R^2, MAE y RMSE.

Para confirmar que la mejora sea estable, se recomienda comparar los modelos con validación cruzada y realizar una evaluación temporal sobre ventas posteriores.

8. Regresión Logística

8.1 Objetivo

Clasificar las transacciones en dos grupos: ventas de importe alto y ventas que no superan el umbral establecido.

La regresión logística estima la probabilidad de pertenecer a la clase de importe alto y asigna una clasificación de acuerdo con el umbral de decisión del modelo.

8.2 Construcción de la variable objetivo

La etiqueta venta_alta se definió a partir del percentil 75 de total_neto calculado en el conjunto de entrenamiento.

El umbral obtenido fue de **$2,155.18**. Los registros que superaron dicho importe se etiquetaron como ventas altas; los restantes se clasificaron como no altos.

La distribución original del entrenamiento fue:

Clase	Registros
No alta	12,980
Alta	4,325



En el conjunto de prueba se registraron 3,258 ventas no altas y 1,069 ventas altas.

Debido al desequilibrio entre las clases, se aplicó sobremuestreo aleatorio a la clase minoritaria únicamente en el entrenamiento. De esta manera, el modelo se ajustó con 12,980 registros por clase, mientras que la prueba conservó la distribución original.

8.3 Resultados

Métrica	Resultado
Accuracy	90.22 %
Precisión de la clase alta	73.20 %
Recall de la clase alta	95.32 %

Métrica	Resultado
F1 de la clase alta	82.81 %
ROC-AUC	96.91 %

El accuracy muestra que el 90.22 % de las predicciones coincidió con las etiquetas reales.

La precisión de 73.20 % indica que aproximadamente siete de cada diez transacciones clasificadas como altas realmente pertenecían a esa categoría.

El recall de 95.32 % indica que el modelo identificó aproximadamente el 95 % de las ventas que realmente eran altas. Esta métrica resulta especialmente relevante cuando el objetivo comercial consiste en evitar que operaciones de importe elevado pasen inadvertidas.

El F1 de 82.81 % resume el equilibrio entre precisión y recall. Por su parte, el ROC-AUC de 96.91 % refleja una elevada capacidad de discriminación entre las clases en los datos evaluados.

8.4 Interpretación comercial

El modelo logístico podría servir como una herramienta exploratoria para priorizar la revisión de transacciones de mayor importe, apoyar la segmentación de operaciones y analizar la composición de las ventas.

Sin embargo, la precisión de 73.20 % implica que una parte de las alertas correspondería a ventas no altas. Por ello, el umbral de clasificación debe ajustarse según el costo comercial de los falsos positivos y los falsos negativos.

Además, el alto desempeño debe interpretarse con cautela, porque las variables predictoras incluyen precio_unitario y total_unidades, que pueden estar estrechamente relacionadas por construcción con total_neto. Esto puede facilitar la clasificación sin demostrar que el modelo identifique señales comerciales independientes.

9. Hallazgos relevantes

A partir de los resultados obtenidos, se identifican los siguientes hallazgos:

1. Asociación muy fuerte entre precio unitario e importe neto. La correlación de Pearson de 0.9927 indica que el precio unitario es la variable numérica con mayor asociación lineal con total_neto entre las candidatas analizadas. Esta relación debe evaluarse considerando la fórmula de facturación y la posible influencia de las unidades vendidas.

2. Mejora moderada de la regresión múltiple. La incorporación de variables adicionales incrementó el R^2 de prueba en 0.0023 y redujo los errores MAE y RMSE. La mejora es favorable, pero debe confirmarse en nuevos periodos de datos.

3. Buena detección de ventas de importe alto. El recall de 95.32 % indica que el modelo logístico detectó una proporción elevada de las ventas de la clase alta. La precisión de 73.20 % muestra que todavía existe margen para reducir las alertas incorrectas.

4. Necesidad de revisar la calidad de los datos. Los 185 duplicados, los 492 códigos postales faltantes y las 1,612 observaciones con importe neto igual a cero son aspectos relevantes para la validación comercial.

5. Presencia de valores extremos. Los posibles valores atípicos de importe y cantidad pueden influir en el ajuste de los modelos y en sus errores. Conviene analizarlos con el área de negocio antes de aplicar transformaciones o exclusiones.

6. Diferencia entre asociación y causalidad. Los resultados permiten describir relaciones estadísticas, pero no demuestran que la marca, el estado, el precio u otra variable provoquen por sí mismos cambios en el importe neto.

10. Implicaciones para el negocio

Los modelos desarrollados pueden contribuir a las siguientes actividades exploratorias:

- **Análisis de transacciones:** identificar características asociadas con importes de venta elevados.
- **Segmentación comercial:** comparar descriptivamente los importes según marca, mes y estado.
- **Priorización de revisiones:** utilizar la clasificación de ventas altas para identificar operaciones que ameriten una revisión comercial.

- **Control de calidad:** investigar registros duplicados, importes cero y operaciones de magnitud inusual.
- **Planeación analítica:** establecer una base para evaluaciones futuras con periodos de datos independientes.

Los resultados no son suficientes, por sí solos, para recomendar cambios de precios, asignaciones de inventario o estrategias comerciales específicas. Esas decisiones requerirían información adicional, validación con responsables del negocio y una evaluación de sus costos y beneficios.

11. Limitaciones del Análisis

El estudio presenta las siguientes limitaciones:

Relación matemática entre variables. El importe neto puede depender directamente del precio unitario y de la cantidad vendida. Por tanto, los elevados valores de R^2 y ROC-AUC podrían reflejar parcialmente esa relación estructural.

Validación limitada. Los resultados provienen de una sola partición aleatoria de entrenamiento y prueba. No se ha demostrado que el rendimiento se mantenga en otro periodo.

Valores extremos y asimetría. Los importes elevados pueden influir en las métricas de regresión y merecen un análisis específico.

Duplicados sin resolución definitiva. Se detectaron 185 filas duplicadas, pero los resultados presentados no corresponden a una evaluación posterior a su eliminación o validación individual.

Interpretación de categorías. Los coeficientes asociados con marcas y estados representan asociaciones condicionadas por el modelo, no efectos causales.

Información temporal. Aunque se derivaron variables de mes y día de la semana, la evaluación aleatoria no sustituye una validación temporal. Para pronosticar ventas futuras sería preferible entrenar con periodos anteriores y evaluar con periodos posteriores.

Alcance de la clasificación. La etiqueta de venta alta es relativa a la distribución del entrenamiento y no representa necesariamente un umbral comercial permanente.

12. Conclusiones

La evaluación permitió aplicar tres técnicas de modelado para analizar el importe neto de las ventas y clasificar las transacciones según su valor económico.

La regresión lineal simple mostró una asociación muy fuerte entre precio_unitario y total_neto, con una correlación de 0.9927 y un R^2 de prueba de 0.9915. Este resultado evidencia que ambas variables están estrechamente relacionadas dentro de los registros analizados.

La regresión lineal múltiple mejoró el desempeño en prueba, con un R^2 de 0.9938, un MAE de $1,189.35 y un RMSE de $2,729.65. La incorporación de variables numéricas y categóricas redujo los errores de predicción respecto al modelo simple.

La regresión logística alcanzó un accuracy de 90.22 %, un recall de 95.32 %, un F1 de 82.81 % y un ROC-AUC de 96.91 %. Estos resultados indican una buena capacidad de discriminación de las ventas altas en la partición evaluada, aunque la precisión de 73.20 % implica que algunas transacciones clasificadas como altas no pertenecían a esa categoría.

En términos de negocio, los modelos ofrecen una base exploratoria para estudiar los importes de venta, la composición de las transacciones y las diferencias observadas entre marcas y estados. Sin embargo, los resultados no deben interpretarse como evidencia de causalidad ni como garantía de desempeño futuro.

Antes de incorporar estas herramientas a procesos operativos, se recomienda validar la calidad de los datos, investigar los registros duplicados y los importes cero, y evaluar los modelos con información de otro periodo. Estas medidas permitirán determinar con mayor confianza su utilidad para apoyar decisiones comerciales.